



T.C ÜSKÜDAR ÜNİVERSİTESİ

FEN BİLİMLERİ ENSTİTÜSÜ

**YAPAY ZEKA MÜHENDİSLİĞİ
YÜKSEK LİSANS**

MAKİNE ÖĞRENMESİ DERSİ FİNAL RAPORU

KONU

**RADYOMİK ÖZELLİKLER KULLANILARAK
PAPİLODEM SINIFLANDIRMASI**

ÖĞRENCİ

254329031

ŞAHİN İNANÇ ÖZKAYA

DANIŞMAN

GÖKALP TULUM

Haziran 2026

ÖZET

Bu çalışmada, normal ve papilödem sınıflarını ayırt etmek amacıyla radyomik özelliklere dayalı ve veri sızıntısını önlemeye odaklanan kapsamlı bir makine öğrenmesi pipeline'ı geliştirilmiştir. Veri seti 966 örnek, 69 hasta/grup ve 746 radyomik özellikten oluşmaktadır. Radyomik yaklaşım, tıbbi görüntülerden çıkarılan yüksek boyutlu nicel özelliklerin sınıflandırma amacıyla kullanılmasına dayanır (Lambin et al., 2012; Gillies et al., 2016).

Çalışmada hasta seviyesinde train, validation ve independent test ayrımı yapılmış; aynı hasta/gruba ait örneklerin farklı alt kümelere düşmesi engellenmiştir. Ön işleme aşamasında median imputation, low-variance filtering, Pearson korelasyonuna dayalı yüksek korelasyon filtresi ve RobustScaler uygulanmıştır. Özellik seçimi için MRMR yöntemi kullanılmış, model hiperparametreleri Optuna TPE sampler ile Macro-F1 hedefi üzerinden optimize edilmiştir (Peng et al., 2005; Akiba et al., 2019).

Independent test sonuçlarına göre zorunlu klasik makine öğrenmesi modelleri arasında en başarılı sample-level model Logistic Regression (LR) olmuştur. LR modeli 0.9898 accuracy, 0.9874 Macro-F1, 0.9995 ROC-AUC ve 0.9988 PR-AUC değerleri üretmiştir. Patient-level değerlendirmede LR ve RBF-SVM modelleri mean probability aggregation ile 14 hasta/grup üzerinde 1.0000 Macro-F1 sonucuna ulaşmıştır. Ancak hasta seviyesindeki test grubunun sınırlı olması nedeniyle bu bulgu ana kanıt olarak değil, sample-level independent test sonuçlarını destekleyen ek analiz olarak yorumlanmıştır.

Bonus analizlerde tabular MLP modeli 0.9876 Macro-F1 ile LR sonucuna çok yakın ve çok küçük farkla daha yüksek bir değer üretmiştir. Bununla birlikte ana model karşılaştırması, ödev yönergesinde zorunlu tutulan klasik makine öğrenmesi modelleri ve veri sızıntısız pipeline kapsamında değerlendirilmiştir. SHAP, LIME, nested cross-validation, feature stability, weighted ensemble optimization ve clinical threshold analizi çalışmanın yorumlanabilirlik ve genellenebilirlik boyutlarını güçlendirmek için eklenmiştir.

1. GİRİŞ

Papilödem, optik disk bölgesinde klinik açıdan dikkat gerektiren bir bulgu olduğu için doğru sınıflandırılması önem taşıyan bir problemdir. Bu çalışmada amaç, radyomik özelliklerden yararlanarak normal ve papilödem örneklerini ayırabilecek, hasta seviyesinde veri sızıntısını önleyen ve akademik olarak savunulabilir bir yapay zeka pipeline'ı geliştirmektir.

Radyomik yaklaşım, görüntülerden elde edilen sayısal özelliklerin modelleme sürecine aktarılmasını sağlar. Bu nedenle çalışma yalnızca model eğitimiyle sınırlandırılmamış; veri ön işleme, özellik seçimi, hiperparametre optimizasyonu, kalibrasyon, ensemble, hasta seviyesinde değerlendirme, istatistiksel testler ve açıklanabilir yapay zeka analizlerini içerecek şekilde tasarlanmıştır. Yüksek boyutlu ve sınırlı hasta sayısına sahip tıbbi veri setlerinde overfitting ve veri sızıntısı temel risklerdir; bu nedenle tüm modelleme aşamalarında eğitim, doğrulama ve test ayrımı dikkatle korunmuştur (Guyon & Elisseeff, 2003). Radyomik özelliklerin hesaplanması ve standardizasyonu açısından PyRadiomics ve IBSI gibi çerçeveler, bu tür nicel görüntü özelliklerinin daha tekrarlanabilir ve karşılaştırılabilir şekilde kullanılmasına katkı sağlamaktadır (Van Griethuysen et al., 2017; Zwanenburg et al., 2020).

2. VERİ SETİ

Veri seti iki ayrı CSV dosyasından oluşmaktadır: normal_radiomics.csv ve papilodem_radiomics.csv. Normal sınıfı 0, papilödem sınıfı 1 olarak etiketlenmiştir. Her örnekte 746 radyomik özellik bulunmaktadır. Model girdisi olarak yalnızca sayısal radyomik özellikler kullanılmış; PatientIndex, SideStandard, target, class_name ve group_id gibi kimlik, taraf veya etiket bilgisi taşıyabilecek kolonlar model özellikleri arasına dahil edilmemiştir.

Tablo 1. Veri seti genel özeti.

Tanım	Değer
Normal örnek sayısı	672
Papilödem örnek sayısı	294
Toplam örnek sayısı	966
Toplam hasta/grup sayısı	69
Radyomik özellik sayısı	746
Sağ/sol ROI dağılımı	483 / 483

Tablo 2. Hasta seviyesinde train/validation/test dağılımı.

Subset	Toplam Örnek	Normal	Papilödem	Hasta/Grup
Train	672	462	210	48
Validation	98	70	28	7
Independent test	196	140	56	14

Bu bölme yapısında aynı hasta/grup hiçbir alt küme arasında ortak değildir. Böylece aynı hastaya ait örneklerin hem eğitim hem test setinde yer alması engellenmiş ve hasta seviyesinde veri sızıntısı riski azaltılmıştır.

3. METODOLOJİ

Metodoloji, radyomik sınıflandırma iş akışına uygun olarak kurulmuştur. Öncelikle veri setleri birleştirilmiş, binary target değişkeni oluşturulmuş ve hasta seviyesinde stratified train/validation/test ayrımı yapılmıştır. Independent test seti; preprocessing fit, MRMR özellik seçimi, Optuna optimizasyonu, calibration veya threshold seçimi aşamalarında kullanılmamıştır.

3.1 Veri Sızıntısını Önleme ve Pipeline Geçerliliği

Her inner cross-validation fold'u içinde preprocessing ve MRMR yalnızca inner-training verisine fit edilmiştir. Validation/test bilgisi, özellik seçimi veya ölçekleme aşamalarına aktarılmamıştır. Hiperparametre optimizasyonunda amaç fonksiyonu Macro-F1 olarak belirlenmiştir. Macro-F1, sınıf dengesizliği bulunan problemlerde her iki sınıfın başarısını birlikte dikkate aldığı için tercih edilmiştir.

- Hasta seviyesinde bölme yapılarak aynı hasta/grubun farklı subsetlere düşmesi engellenmiştir.
- Preprocessing yalnızca eğitim verisine fit edilmiştir.
- MRMR seçimi cross-validation içinde yeniden uygulanmıştır.
- Threshold seçimi validation set üzerinde yapılmış, test seti yalnızca final değerlendirmede kullanılmıştır.


- Final deęerlendirmede sample-level ve patient-level sonuçlar ayrı ayrı raporlanmıřtır.

4. VERİ ÖN İřLEME

Ön iřleme ařamasında median imputation, low-variance filtering, Pearson korelasyonuna dayalı yüksek korelasyon filtresi ve RobustScaler uygulanmıřtır. Veri setinde eksik deęer bulunmamasına raęmen imputation yapısı metodolojik bütünlük ve olası eksik veri senaryolarına dayanıklılık için pipeline içinde tutulmuřtur. RobustScaler, uç deęerlerin etkisini sınırlamak amacıyla kullanılmıřtır.

Tablo 3. Ön iřleme ařamalarına göre özellik sayıları.

Ön İřleme Ařaması	Özellik Sayısı
Bařlangıç radyomik özellikleri	746
Low-variance filtering sonrası	719
High-correlation filtering sonrası	237
RobustScaler sonrası final özellik seti	237



řekil 1. Ön iřleme sonrası özellik sayısındaki deęiřim.


Başlangıçta 746 olan özellik sayısı, düşük varyans filtresi sonrasında 719'a, yüksek korelasyon filtresi sonrasında ise 237'ye düşmüştür. Bu azalma, yüksek boyutlu radyomik veri setinde tekrarlı veya aşırı benzer bilgi taşıyan özelliklerin önemli bir bölümünün elendiğini göstermektedir.

5. ÖZELLİK SEÇİMİ

Özellik seçimi için MRMR yaklaşımı kullanılmıştır. MRMR, hedef sınıfla ilişkisi yüksek olan özellikleri seçerken birbirleriyle aşırı benzerlik taşıyan özelliklerin tekrarını azaltmayı amaçlar. Bu çalışmada relevance ölçüsü mutual information, redundancy ölçüsü ortalama mutlak Pearson korelasyonu olarak tanımlanmıştır (Peng et al., 2005).

Tablo 4. LR final modelinde MRMR ile seçilen ilk 10 özellik.

Sıra	Özellik	Mutual Information	MRMR Skoru
1	Feature_0224	0.3356	1.0000
2	Feature_0408	0.3304	0.6516
3	Feature_0409	0.3192	0.5393
4	Feature_0028	0.2670	0.4774
5	Feature_0478	0.2625	0.4210
6	Feature_0034	0.2569	0.3833
7	Feature_0086	0.2530	0.3861
8	Feature_0135	0.1714	0.3549
9	Feature_0072	0.2275	0.3806
10	Feature_0040	0.2204	0.3819




Şekil 2. MRMR ile seçilen özelliklerin skorları.

Tablo 5. MRMR kullanılmadan ve MRMR ile test karşılaştırması.

Model	Ayar	Özellik Sayısı	Threshold	Accuracy	Precision	Recall	Macro-F1	ROC-AUC	PR-AUC	TN	FP	FN	TP
LR	Without MRMR	237	0.8900	0.8776	0.8636	0.6786	0.8389	0.9301	0.8899	134	6	18	38
LR	With MRMR	50	0.9500	0.9949	0.9825	1.0000	0.9938	1.0000	1.0000	139	1	0	56
RBF-SVM	Without MRMR	237	0.3200	0.7143	0.0000	0.0000	0.4167	0.9568	0.8282	140	0	56	0
RBF-SVM	With MRMR	20	0.5600	0.9694	0.9808	0.9107	0.9617	0.9935	0.9870	139	1	5	51

MRMR karşılaştırması, özellik seçiminin yalnızca boyut azaltma sağlamadığını, aynı zamanda pratik sınıflandırma performansını da belirgin biçimde artırdığını göstermektedir. LR modelinde MRMR kullanılmadan Macro-F1 0.8389 iken, MRMR ile 0.9938'e yükselmiştir. RBF-SVM modelinde ise MRMR olmadan papilödem sınıfı yakalanamazken, MRMR sonrasında Macro-F1 0.9617 olmuştur. Bu nedenle MRMR, yüksek boyutlu radyomik veri yapısında kritik bir modelleme adımı olarak değerlendirilmiştir.




Şekil 3. LR modeli için MRMR etkisi.

6. MODELLEME VE HİPERPARAMETRE OPTİMİZASYONU

Çalışmada Logistic Regression (LR), RBF-SVM, Random Forest (RF), Extra Trees (ET), Gradient Boosting (GB) ve KNN modelleri eğitilmiştir. Ayrıca RF, ET ve GB modellerinden oluşan soft voting ensemble kurulmuştur. Hiperparametre optimizasyonu Optuna TPE sampler ile yürütülmüş ve her model için en az 50 trial uygulanmıştır. Modelleme ve metrik hesaplama adımlarında scikit-learn ekosisteminden yararlanılmıştır (Pedregosa et al., 2011; Akiba et al., 2019).

Tablo 6. Optuna sonucunda elde edilen en iyi inner CV sonuçları ve parametre özeti.

Model	Best Inner CV Macro-F1	En İyi Parametreler
GB	0.8765	{'n_mrmr_features': 20, 'n_estimators': 300, 'learning_rate': 0.049276780545154386, 'max_depth': 4, 'min_samples_sp...
RBF-SVM	0.8702	{'n_mrmr_features': 20, 'C': 3.6890627355848817, 'gamma': 0.1824631857395044, 'class_weight': None}
ET	0.8690	{'n_mrmr_features': 20, 'n_estimators': 500, 'max_depth': 16, 'min_samples_split': 2, 'min_samples_leaf': 1, 'max_f...
KNN	0.8687	{'n_mrmr_features': 40, 'n_neighbors': 7, 'weights': 'distance', 'metric': 'manhattan'}
RF	0.8643	{'n_mrmr_features': 20, 'n_estimators': 500, 'max_depth': 16, 'min_samples_split': 6, 'min_samples_leaf': 3, 'max_f...
LR	0.8534	{'n_mrmr_features': 50, 'C': 70.47325306682897, 'class_weight': None}



Şekil 4. Final Optuna en iyi inner CV Macro-F1 sonuçları.


Inner CV sonuçlarında GB, RBF-SVM, ET, KNN, RF ve LR modelleri birbirine yakın performans üretmiştir. Bu sonuç final test sıralamasının birebir aynısı olmak zorunda değildir; çünkü inner CV eğitim alanı içindeki model seçimi aşamasını, independent test ise dışarıda tutulan final performansı temsil eder.

7. KALİBRASYON VE THRESHOLD OPTİMİZASYONU

Model olasılık çıktıları sigmoid calibration ile kalibre edilmiştir. Sigmoid calibration, model skorlarını olasılıksal çıktılara dönüştürmek ve olasılık tahminlerinin güvenilirliğini değerlendirmek için kullanılan yaygın bir yaklaşımdır (Platt, 1999; Niculescu-Mizil & Caruana, 2005). Veri sızıntısını önlemek için kalibrasyon training verisi üzerinde out-of-fold olasılıklar kullanılarak fit edilmiştir. Threshold seçimi validation set üzerinde Macro-F1 hedefiyle yapılmıştır.

Tablo 7. Raw ve calibrated olasılık çıktıların Brier/ECE karşılaştırması.

Model	Raw Brier	Calibrated Brier	Raw ECE-10	Calibrated ECE-10
GB	0.0501	0.0457	0.0474	0.0603
ET	0.0376	0.0384	0.0607	0.0572
RF	0.0449	0.0467	0.0600	0.0598
LR	0.0264	0.0320	0.0474	0.1334
RBF-SVM	0.0219	0.0277	0.0324	0.0723
KNN	0.0368	0.0482	0.0359	0.0577


**Şekil 5. Final test calibration curve grafikleri.**

Kalibrasyon sonuçları model bazında farklılık göstermiştir. GB modelinde Brier Score iyileşirken, ET ve RF modellerinde ECE-10 küçük iyileşme göstermiştir. LR ve RBF-SVM modellerinde calibrated ECE-10 raw ECE-10 değerinden daha yüksek çıkmıştır. Bu nedenle kalibrasyonun her modelde otomatik iyileşme sağlamadığı, olasılık güvenilirliğinin Brier Score ve ECE-10 ile ayrıca değerlendirilmesi gerektiği görülmüştür.


Tablo 8. LR standart ve klinik recall odaklı threshold karşılaştırması.

Model	Ayar	Threshold	Accuracy	Precision	Recall	Macro-F1	TN	FP	FN	TP
LR	Standard									
	Macro-F1 Threshold	0.5400	0.9898	1.0000	0.9643	0.9874	140	0	2	54
LR	Clinical									
	Recall-Oriented Threshold	0.5400	0.9898	1.0000	0.9643	0.9874	140	0	2	54

Clinical recall-oriented threshold analizi final sample-level en iyi klasik model olan LR üzerinde yapılmıştır. Validation set üzerinde recall odaklı kural uygulandığında seçilen threshold standart Macro-F1 threshold ile aynı kalmıştır. Bu nedenle independent testte clinical threshold ek bir performans değişikliği üretmemiş; LR modeli 2 false negative ve 0 false positive ile sonuçlanmıştır.



Şekil 6. LR standart threshold confusion matrix.



Şekil 8. Weighted ensemble confusion matrix.

9. BULGULAR


Independent test değerlendirmesi 196 örnek üzerinde yapılmıştır. Zorunlu klasik makine öğrenmesi modelleri arasında en yüksek sample-level Macro-F1 değerini Logistic Regression modeli üretmiştir. LR modeli 140 normalörneğin tamamını doğru sınıflandırmış, 56 papilödemörneğin 54'ünü doğru tahmin etmiş ve 2 false negative üretmiştir.

Tablo 10. Independent test sample-level sınıflandırma metrikleri.


Model	Threshold	Accuracy	Precision	Recall	F1-score	Macro-F1	Balanced Accuracy
LR	0.5400	0.9898	1.0000	0.9643	0.9818	0.9874	0.9821
RBF-SVM	0.4800	0.9694	0.9808	0.9107	0.9444	0.9617	0.9518
KNN	0.4000	0.9643	1.0000	0.8750	0.9333	0.9545	0.9375
ET	0.4000	0.9592	1.0000	0.8571	0.9231	0.9476	0.9286
Soft Voting Ensemble	0.4000	0.9541	0.9796	0.8571	0.9143	0.9415	0.9250
GB	0.5600	0.9337	0.9778	0.7857	0.8713	0.9133	0.8893
RF	0.4000	0.9286	0.9565	0.7857	0.8627	0.9072	0.8857

Tablo 11. Independent test olasılık ve kalibrasyon metrikleri.


Model	ROC-AUC	PR-AUC	Brier Score	ECE-10
LR	0.9995	0.9988	0.0320	0.1334
RBF-SVM	0.9950	0.9901	0.0277	0.0723
KNN	0.9548	0.9407	0.0482	0.0577
ET	0.9901	0.9812	0.0384	0.0572
Soft Voting Ensemble	0.9867	0.9741	0.0426	0.0609
GB	0.9844	0.9686	0.0457	0.0603
RF	0.9841	0.9695	0.0467	0.0598




Şekil 9. Independent test ROC eğrileri.




Şekil 10. Independent test Precision-Recall eğrileri.



Şekil 11. En iyi zorunlu klasik model olan LR için confusion matrix.



Şekil 12. Final test Macro-F1 model karşılaştırması.




Şekil 13. LR modeli için permutation feature importance.

10. PATİENT-LEVEL DEĞERLENDİRME

Patient-level değerlendirme, aynı hasta/grup içindeki örneklerin olasılıklarının birleştirilmesiyle yapılmıştır. Validation set üzerinde farklı aggregation stratejileri denenmiş ve final testte seçilen stratejiler uygulanmıştır. Mean probability aggregation tüm modeller için seçilen ana strateji olmuştur.

Tablo 12. Patient-level independent test sonuçları.

Model	Aggregation	Hasta Sayısı	Accuracy	Recall	Macro-F1	ROC-AUC	PR-AUC	Brier Score	ECE-10
LR	mean_proba	14	1.0000	1.0000	1.0000	1.0000	1.0000	0.0250	0.1394
RBF-SVM	mean_proba	14	1.0000	1.0000	1.0000	1.0000	1.0000	0.0184	0.0996
RF	mean_proba	14	0.9286	0.7500	0.9048	1.0000	1.0000	0.0400	0.1204
ET	mean_proba	14	0.9286	0.7500	0.9048	1.0000	1.0000	0.0327	0.1021
GB	mean_proba	14	0.9286	0.7500	0.9048	1.0000	1.0000	0.0385	0.1266
KNN	mean_proba	14	0.9286	0.7500	0.9048	1.0000	1.0000	0.0350	0.1153
Soft Voting Ensemble	mean_proba	14	0.9286	0.7500	0.9048	1.0000	1.0000	0.0367	0.1164



Şekil 14. Patient-level Macro-F1 model karşılaştırması.

LR ve RBF-SVM modelleri patient-level değerlendirmede 14 hasta/grup üzerinde 1.0000 Macro-F1 değerine ulaşmıştır. Bu sonuç, hasta içindeki birden fazla örneğin olasılıklarının ortalaması alındığında model kararlarının daha kararlı hale geldiğini göstermektedir. Ancak hasta seviyesindeki test grubunun yalnızca 14 gruptan oluşması nedeniyle bu bulgu ana genellenebilirlik kanıtı olarak değil, destekleyici analiz olarak değerlendirilmiştir.

11. İSTATİSTİKSEL ANALİZ

Model performanslarının tekrarlı hasta seviyeli bölmelerde karşılaştırılması için repeated split sonuçları kullanılmıştır. Genel fark için Friedman testi, ikili model karşılaştırmaları için Wilcoxon signed-rank testi ve çoklu karşılaştırma kontrolü için Bonferroni correction uygulanmıştır. Bu yaklaşım, çoklu sınıflandırıcı karşılaştırmalarında parametrik olmayan istatistiksel değerlendirme amacıyla kullanılmaktadır (Demšar, 2006).

Tablo 13. Friedman test sonucu.


Test	Statistic	p-value	alpha=0.05 Anlamlı mı?
Friedman Test	37.6166	0.0000	True

Tablo 14. Repeated patient-level split sanity check özeti.

Model	Macro-F1 Ortalama	Macro-F1 Std	ROC-AUC Ortalama	PR-AUC Ortalama	Accuracy Ortalama
ET	0.8946	0.0831	0.9270	0.9099	0.9221
RBF-SVM	0.8854	0.0703	0.9148	0.8920	0.9114
RF	0.8840	0.0829	0.9159	0.8981	0.9130
KNN	0.8769	0.0750	0.9162	0.8557	0.9055
GB	0.8727	0.0755	0.9063	0.8899	0.9026
LR	0.8133	0.0725	0.8893	0.8623	0.8464

Tablo 15. Bonferroni sonrası anlamlı kalan Wilcoxon karşılaştırmaları.

Model A	Model B	Mean Macro-F1 A	Mean Macro-F1 B	Bonferroni p
LR	RBF-SVM	0.8133	0.8854	0.0000
ET	LR	0.8946	0.8133	0.0004
LR	RF	0.8133	0.8840	0.0009
GB	LR	0.8727	0.8133	0.0044
KNN	LR	0.8769	0.8133	0.0094



Şekil 15. Repeated split Macro-F1 ortalama ve standart sapma grafiği.

Repeated split analizinde ET, RBF-SVM ve RF modelleri ortalama Macro-F1 açısından yüksek değerler üretmiş, LR ise bu diagnostik analizde daha düşük ortalama göstermiştir. Bu sonuç, tek bir final test bölmesi ile repeated development split analizinin farklı değerlendirme düzeylerini temsil ettiğini göstermektedir. Final ana karar independent test üzerinde verilirken, repeated split sonuçları model performansının hasta bölmelerine duyarlılığını göstermektedir.

12. AÇIKLANABİLİR YAPAY ZEKA ANALİZLERİ


Açıklanabilirlik iki düzeyde ele alınmıştır. Final sample-level en iyi zorunlu klasik model LR olduğu için birincil özellik önem sıralaması LR permutation importance üzerinden verilmiştir. Destekleyici/bonus analiz kapsamında RBF-SVM modeli için SHAP ve LIME uygulanmıştır. SHAP global özellik önemini, LIME ise tekil örnek kararlarını yorumlamak için kullanılmıştır (Lundberg & Lee, 2017; Ribeiro et al., 2016).

Tablo 16. LR permutation importance ilk 10 özellik.


Özellik	Importance Mean	Importance Std
Feature_0409	0.3855	0.0344
Feature_0088	0.3160	0.0260
Feature_0028	0.3118	0.0251
Feature_0453	0.2261	0.0158
Feature_0644	0.2069	0.0281
Feature_0456	0.1610	0.0172
Feature_0085	0.1414	0.0186
Feature_0003	0.1262	0.0170
Feature_0084	0.1164	0.0207
Feature_0408	0.1027	0.0163

Tablo 17. RBF-SVM SHAP global importance ilk 10 özellik.


Özellik	Mean SHAP
Feature_0224	0.0468
Feature_0028	0.0450
Feature_0442	0.0373
Feature_0409	0.0337
Feature_0008	0.0306
Feature_0408	0.0303
Feature_0500	0.0274
Feature_0043	0.0232
Feature_0040	0.0195
Feature_0135	0.0173




Şekil 16. RBF-SVM SHAP global feature importance.



Şekil 17. RBF-SVM SHAP summary plot.



Şekil 18. LIME normal örnek açıklaması.



Şekil 19. LIME papilodem örnek açıklaması.

Açıklanabilirlik çıktıları biyolojik nedensellik kanıtı olarak değil, modelin karar mekanizmasını anlamaya yardımcı olan model-temelli yorumlama çıktıları olarak değerlendirilmelidir. Özellikle Feature_0409, Feature_0088, Feature_0028 ve Feature_0408 gibi özellikler LR permutation analizinde öne çıkmış; RBF-SVM SHAP analizinde ise Feature_0224, Feature_0028, Feature_0442 ve Feature_0409 dikkat çekmiştir.


13. BONUS ÇALIŞMALAR

13.1 Feature Stability Analizi

MRMR seçimlerinin farklı hasta bölmelerinde ne kadar kararlı olduğunu değerlendirmek için feature stability analizi yapılmıştır. Bu analiz son çalışma versiyonunda final sample-level en iyi zorunlu klasik model olan LR'nin MRMR özellik sayısı dikkate alınarak gerçekleştirilmiştir. Bu nedenle stabil özellik sayısı, 50 özellik seçen LR yapısına göre yorumlanmalıdır.

Tablo 18. Feature stability threshold özeti.

Selection Frequency Threshold	Stable Feature Count
0.5000	49
0.6000	47
0.7000	45
0.8000	42




Şekil 20. MRMR feature stability top 30.

Selection frequency threshold 0.50 iken 49 özellik stabil kabul edilmiştir. Bu yüksek sayı, LR için her splitte 50 MRMR özelliği seçilmesinden etkilenmektedir; dolayısıyla sonuç, özellikle belirli bir grup özelliğin repeated splitlerde tutarlı seçildiğini göstermektedir.

13.2 Deep Learning Modeli

Tablo 19. Deep learning MLP independent test sonucu.

Model	Threshold	N MRMR	Accuracy	Precision	Recall	Macro- F1	ROC- AUC	PR- AUC	Brier Score	ECE-10
Deep Learning MLP	0.6000	50	0.9898	0.9655	1.0000	0.9876	1.0000	1.0000	0.0090	0.0223




Şekil 21. Deep learning training history.

Bonus tabular MLP modeli 0.9898 accuracy, 1.0000 recall, 0.9876 Macro-F1 ve 1.0000 ROC-AUC/PR-AUC değerleri üretmiştir. Bu değer LR sonucuna çok yakındır ve Macro-F1 açısından çok küçük farkla daha yüksektir. Ancak MLP bu ödevde opsiyonel/bonus model olduğu için ana zorunlu klasik model karşılaştırması LR üzerinden raporlanmıştır.

13.3 Nested Cross-Validation

Tablo 20. RBF-SVM nested cross-validation özet sonuçları.

Metric	Mean	Std
Accuracy	0.8792	0.0458
Precision	0.8737	0.1247
Recall	0.7369	0.2907
F1-score	0.7544	0.1834
Macro-F1	0.8354	0.1022
Balanced Accuracy	0.8367	0.1196
ROC-AUC	0.8991	0.0881
PR-AUC	0.8531	0.0996
Brier Score	0.0977	0.0418
ECE-10	0.1088	0.0296



Şekil 22. Nested CV outer fold Macro-F1 grafiği.

Nested CV sonucunda RBF-SVM için ortalama Macro-F1 0.8354, ROC-AUC 0.8991 ve PR-AUC 0.8531 olarak hesaplanmıştır. Bu değerler final independent test performansından düşüktür. Bu durum çalışmanın hatalı olduğunu değil, sınırlı hasta/grup sayısında performansın hasta bölmelerine duyarlı olabileceğini göstermektedir.

14. ZORUNLU DEĞERLENDİRME SORULARINA YANITLAR

1. Hangi model en iyi performansı verdi?

Zorunlu klasik makine öğrenmesi modelleri arasında independent test sample-level sonuçlarına göre en iyi performansı Logistic Regression modeli vermiştir. LR modeli 0.9898 accuracy, 0.9874 Macro-F1, 0.9995 ROC-AUC ve 0.9988 PR-AUC değerlerine ulaşmıştır. Bonus MLP modeli Macro-F1 açısından 0.9876 ile LR sonucuna çok küçük farkla yakın/üst düzey bir değer üretmiştir; ancak ana model seçimi zorunlu klasik model karşılaştırması kapsamında LR olarak yapılmıştır.

2. Ensemble model tekli modellerden daha iyi mi?

Hayır. Soft voting ensemble güçlü performans göstermesine rağmen en iyi tekil klasik model olan LR modelini geçememiştir. Soft voting ensemble Macro-F1 değeri 0.9415 iken LR Macro-F1 değeri 0.9874'tür. Weighted ensemble optimization ise RF=0, ET=0 ve GB=1 ağırlığına indirgenmiş, yani pratikte GB modeline eşdeğer sonuç üretmiştir.

3. MRMR özellik seçimi performansı artırdı mı?

Evet. LR modelinde MRMR kullanılmadan Macro-F1 0.8389 iken MRMR ile 0.9938'e yükselmiştir. RBF-SVM modelinde ise MRMR olmadan Macro-F1 0.4167 ve recall 0.0000 iken, MRMR ile Macro-F1 0.9617 ve recall 0.9107 olmuştur. Bu sonuçlar MRMR'nin hem boyut azaltma hem de sınıflandırma performansı açısından önemli katkı sağladığını göstermektedir.

4. Kalibrasyon model güvenilirliğini artırdı mı?

Kısmen. Kalibrasyon metodolojik olarak uygulanmıştır; ancak tüm modellerde tutarlı bir güvenilirlik artışı sağlamamıştır. GB modelinde Brier Score iyileşmiş, ET ve RF modellerinde ECE-10 küçük iyileşme göstermiştir. LR ve RBF-SVM modellerinde calibrated ECE-10 raw ECE-10 değerinden yüksek çıkmıştır. Bu nedenle kalibrasyonun etkisi model bazında değerlendirilmiştir.

5. ROC-AUC ile PR-AUC sonuçları arasında nasıl bir ilişki gözlemlendi?

ROC-AUC ve PR-AUC sonuçları genel olarak paralel şekilde yüksek bulunmuştur. LR modelinde ROC-AUC 0.9995, PR-AUC 0.9988 düzeyindedir. Papilödem sınıfı normal sınıfa göre daha az örnek içerdiği için PR-AUC, pozitif sınıf performansını değerlendirmede özellikle önemlidir.

6. Veri boyutunun model performansına etkisi nedir?

Veri setinde 966 örneğe karşılık 746 radyomik özellik bulunması overfitting riskini artırmaktadır. Bu nedenle düşük varyans filtresi, korelasyon filtresi, RobustScaler ve MRMR uygulanmıştır. Nested CV sonuçlarının final testten düşük olması da sınırlı hasta/grup sayısının genellenebilirlik üzerinde etkili olabileceğini göstermektedir.

7. En önemli ilk 10 radyomik özellik hangileridir?

Final sample-level en iyi zorunlu klasik model LR olduğu için ana ilk 10 özellik permutation importance ile belirlenmiştir: Feature_0409, Feature_0088, Feature_0028, Feature_0453, Feature_0644, Feature_0456, Feature_0085, Feature_0003, Feature_0084 ve Feature_0408. RBF-SVM SHAP analizinde ise Feature_0224, Feature_0028, Feature_0442 ve Feature_0409 öne çıkmıştır.

15. Bulguların Genel Yorumu

Bu çalışmada elde edilen sonuçlar, radyomik özelliklerin papilödem sınıflandırması için güçlü bir ayırt edici sinyal taşıdığını göstermektedir. Independent test setinde LR modelinin yüksek Macro-F1, ROC-AUC ve PR-AUC değerleri üretmesi, seçilen radyomik özelliklerin normal ve papilödem sınıflarını ayırmada etkili olduğunu desteklemektedir. Bununla birlikte klinik bağlamda yalnızca accuracy değerine bakmak yeterli değildir; false negative hatalar ayrıca değerlendirilmelidir. LR modelinde sample-level değerlendirmede 2 papilödem örneği normal olarak sınıflandırılmıştır.

Patient-level değerlendirmede LR ve RBF-SVM modelleri 14 hasta/grup üzerinde 1.0000 Macro-F1 değerine ulaşmıştır. Bu sonuç hasta seviyesinde aggregation yaklaşımının faydalı

olabileceğini gösterse de hasta sayısının sınırlı olması nedeniyle dikkatli yorumlanmalıdır. Bu nedenle ana sonuç sample-level independent test üzerinden verilmiş, patient-level sonuç destekleyici bulgu olarak sunulmuştur.

MRMR karşılaştırması, çalışmanın en güçlü metodolojik bulgularından biridir. Hem LR hem RBF-SVM için MRMR sonrasında performansın belirgin şekilde artması, yüksek boyutlu radyomik veri setinde tüm özellikleri kullanmanın her zaman daha iyi sonuç vermediğini göstermektedir. Gürültülü, tekrarlı veya zayıf özelliklerin elenmesi modelin karar sınırını daha kararlı hale getirmiştir.

Kalibrasyon sonuçları daha karmaşık bir tablo sunmuştur. Bazı modellerde Brier Score veya ECE-10 iyileşirken, bazı modellerde raw olasılıklar daha iyi görünmüştür. Bu nedenle kalibrasyonun amacı sınıf tahminini artırmak değil, olasılık güvenilirliğini ayrıca değerlendirmek olarak yorumlanmıştır. Bu bulgu özellikle tıbbi karar destek sistemlerinde olasılık skorlarının tek başına kesin klinik karar olarak kullanılmaması gerektiğini göstermektedir.

Nested cross-validation sonucunun final independent test performansından daha düşük çıkması, çalışmanın dengeli yorumlanması açısından önemlidir. Bu sonuç modelin yanlış olduğunu değil, sınırlı hasta/grup sayısında performansın bölmelere duyarlı olduğunu gösterir. Dolayısıyla sonuçlar güçlü olsa da daha geniş ve dış merkezli veri setleriyle doğrulama yapılmadan klinik kullanım iddiasında bulunulmamalıdır.

16. TARTIŞMA

Elde edilen bulgular, radyomik özelliklere dayalı bir makine öğrenmesi sisteminin papilödem sınıflandırmasında yüksek başarı gösterebileceğini ortaya koymaktadır. Çalışmanın güçlü yönleri arasında hasta seviyesinde split, veri sızıntısını önleyen preprocessing ve MRMR yapısı, Optuna ile hiperparametre optimizasyonu, kalibrasyon, ensemble, istatistiksel karşılaştırma ve açıklanabilirlik analizleri bulunmaktadır.

Bununla birlikte çalışmanın temel sınırlılığı hasta/grup sayısının sınırlı olmasıdır. Veri seti 966 örnek içerse de bağımsız testte hasta/grup sayısı 14'tür. Bu nedenle patient-level sonuçlar destekleyici bulgu olarak değerlendirilmiştir. Ayrıca final independent testte çok yüksek performans elde edilmesine rağmen nested CV sonuçları daha düşük ve değişken bir performans göstermiştir. Bu durum daha geniş veri setlerinde dış doğrulama ihtiyacını ortaya koymaktadır.

Ensemble modelin en iyi tekil klasik modeli geçememesi beklenmedik değildir. Ensemble modeller benzer hata örüntülerine sahip bileşenlerden oluştuğunda ek performans kazanımı sınırlı kalabilir. Weighted ensemble sonucunun tek bir modele indirgenmesi de bu veri setinde RF, ET ve GB kombinasyonunun LR kadar güçlü bir karar sınırı üretmediğini göstermektedir.

Bonus MLP modelinin yüksek performansı, radyomik özellik uzayında doğrusal olmayan temsillerin de etkili olabileceğini göstermektedir. Ancak veri setinin görece sınırlı hasta sayısı, deep learning modellerinin overfitting riskini artırır. Bu nedenle MLP sonucu destekleyici olarak verilmiş, ana sonuç daha yorumlanabilir ve zorunlu klasik model grubu içindeki LR modeli üzerinden değerlendirilmiştir.

17. SONUÇ

Bu final projesinde radyomik özellikler kullanılarak papilödem sınıflandırması için veri sızıntısını önleyen, hasta seviyesinde bölme yapan ve akademik değerlendirme adımlarını içeren kapsamlı bir makine öğrenmesi pipeline'ı geliştirilmiştir. Independent test setinde zorunlu klasik makine öğrenmesi modelleri arasında en başarılı sample-level model Logistic Regression olmuştur. LR modeli yüksek accuracy, Macro-F1, ROC-AUC ve PR-AUC değerleriyle güçlü bir sınıflandırma performansı göstermiştir.

MRMR özellik seçimi performansı belirgin şekilde artırmış, ensemble model en iyi tekil modeli geçememiş, kalibrasyon ise model bazında değişen etkiler göstermiştir. Patient-level değerlendirme destekleyici olarak güçlü sonuçlar üretmiş; ancak sınırlı hasta/grup sayısı nedeniyle dış veriyle doğrulama ihtiyacı vurgulanmıştır. SHAP, LIME, feature stability, MLP, weighted ensemble optimization ve nested cross-validation analizleri çalışmanın kapsamını

geniřletmiřtir. Genel olarak alıřma, radyomik zelliklere dayalı papildem sınıflandırması iin gl, dzenli ve bilimsel olarak savunulabilir bir yapay zeka pipeline'ı ortaya koymuřtur.

KAYNAKÇA

- Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2623-2631.
- Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7, 1-30.
- Gillies, R. J., Kinahan, P. E., & Hricak, H. (2016). Radiomics: Images are more than pictures, they are data. *Radiology*, 278(2), 563-577.
- Guyon, I., & Elisseeff, A. (2003). An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3, 1157-1182.
- Lambin, P., Rios-Velazquez, E., Leijenaar, R., Carvalho, S., van Stiphout, R. G., Granton, P., ... & Aerts, H. J. (2012). Radiomics: Extracting more information from medical images using advanced feature analysis. *European Journal of Cancer*, 48(4), 441-446.
- Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.
- Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. *Proceedings of the 22nd International Conference on Machine Learning*, 625-632.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Peng, H., Long, F., & Ding, C. (2005). Feature selection based on mutual information: Criteria of max-dependency, max-relevance, and min-redundancy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 27(8), 1226-1238.
- Platt, J. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. *Advances in Large Margin Classifiers*, 10(3), 61-74.
- Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). Why should I trust you? Explaining the predictions of any classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135-1144.
- Van Griethuysen, J. J. M., Fedorov, A., Parmar, C., Hosny, A., Aucoin, N., Narayan, V., ... & Aerts, H. J. W. L. (2017). Computational radiomics system to decode the radiographic phenotype. *Cancer Research*, 77(21), e104-e107.
- Zwanenburg, A., Vallières, M., Abdalah, M. A., Aerts, H. J. W. L., Andrearczyk, V., Apte, A., ... & Löck, S. (2020). The Image Biomarker Standardisation Initiative: Standardized quantitative radiomics for high-throughput image-based phenotyping. *Radiology*, 295(2), 328-338.